

RESEARCH ARTICLE

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

姓名：林创锐 学号：2023303003

 λ_{target} : 480 nm seed: 303003 design_seed: 303004

摘要

多层介质薄膜的反射光谱由各层厚度经干涉效应决定，正向计算依赖传输矩阵法（TMM），评估大量候选时代价不可忽略。以 Air/H/L/H/L/Glass 四层膜为对象，用 TMM 生成 5000 组膜厚—光谱数据并训练 MLP 代理模型。测试集平均绝对误差 0.00638， $R^2 = 0.9977$ ；误差随训练样本数按 $N^{-1.031}$ 幂律下降且边际收益递减，该指数本身随网络容量在 0.43–1.38 间变化；容量与膜厚空间的局部采样稀疏（ $r = 0.370$ ）共同限制精度，而非波长采样。10000 组候选中，MLP 排序与 TMM 真值的相关系数为 0.9983；所选设计经 TMM 复核达四分之一波长上限 0.6589 的 99.8%。代理模型可快速压缩候选规模，最终须由 TMM 复核。

关键词 光学薄膜；传输矩阵法；多层感知机；代理模型；逆向设计；AI for Science

1. 引言

多层介质薄膜由高、低折射率材料交替堆叠而成，其反射特性来自各界面反射光之间的干涉；在正入射、无吸收、忽略色散的条件下，给定各层折射率与厚度，光谱响应即完全确定^[1,2]。反之，要在某波长获得特定反射率则需确定各层厚度，这是多变量、非线性的设计问题。四分之一波长条件给出了经典解，但膜厚的周期性与光谱的多峰特性使“厚度—光谱”映射呈现强非线性，传统优化算法（如针式法）需要大量迭代^[3]。

传输矩阵法（TMM）是计算多层膜光谱的经典方法：把每层写成一个 2×2 特征矩阵，沿膜系连乘后由等效导纳得到反射率^[1,2]。单条光谱的计算开销很小，但当设计流程需要评估上万组候选结构时，累积代价迅速上升；若再考虑色散、斜入射与吸收，单次前向计算的成本还会显著增加^[4]。

机器学习代理模型提供了另一条路径：用数据学习“膜厚到光谱”的映射，以极低的推理成本替代物理计算，用于大规模候选的初筛，最终结果再由物理模型复核^[5,6]，这正是 AI for Science 的典型范式^[4]。这一思路已在多层膜体系中以串联网、序列生成等不同形式实现^[7,8]，而荧光等纳米结构的光谱—结构双向映射也验证了其可行性^[9]。本文围绕三个问题展开：（1）MLP 能否准确预测反射光谱；（2）训练数据量增加后预测误差如何变化；（3）MLP 能否作为辅助手段完成目标波长下的薄膜设计。研究对象、目标波长与随机种子均按课程要求由学号统一确定，全部结果可由公开代码复现。




图1 本研究的总体流程：TMM 生成数据、MLP 训练与预测、数据量实验、辅助设计与 TMM 复核。

2. 材料与方法

2.1 光学模型与传输矩阵法

研究对象为 Air/H/L/H/L/Glass 四层介质膜，正入射、无吸收、忽略色散。高、低折射率材料取 $n_H = 2.30$ 与 $n_L = 1.45$ ，基底 $n_s = 1.52$ ，入射介质为空气 $n_0 = 1.00$ ；每层膜厚 40–180 nm，波长 400–800 nm、步长 10 nm，共 41 点。

第 i 层的位相厚度为

$$\delta_i = 2\pi n_i d_i / \lambda$$

其特征矩阵为

$$M_i = \begin{pmatrix} \cos \delta_i & i \sin \delta_i / \eta_i \\ i \eta_i \sin \delta_i & \cos \delta_i \end{pmatrix}$$

其中正入射下光学导纳 $\eta_i = n_i$ （自由空间单位）^[1,2]。整个膜系的特征矩阵为各层矩阵按入射到出射顺序的连乘 $M = M_1 M_2 M_3 M_4$ ，由

$$[B; C] = M [1; \eta_s], Y = C/B, r = \frac{\eta_0 - Y}{\eta_0 + Y}, R = |r|^2$$

即由等效导纳 $Y = C/B$ 得到反射系数 r 与反射率 R 。

本文用两套独立实现计算 R ：一是上述特征矩阵连乘；二是从基底出发的等效导纳递推

$$Y \leftarrow \frac{Y \cos \delta + i \eta \sin \delta}{\cos \delta + i (Y/\eta) \sin \delta}$$

二者数学等价但代码路径不同，用于互相验错。校核结果：裸基底与解析值 4.258% 差 7×10^{-18} ；四分之一波长膜系在 480 nm 处与导纳链解析值 0.6589 差 1×10^{-16} ；200 组单层膜与解析式的最大偏差 6×10^{-16} ；两套实现在 2000 组随机膜厚上的最大差异 9×10^{-16} ；与在线 TMM 工具核对的最大偏差 6×10^{-16} 。




图 2 物理模型与 TMM 数据生成：(a) 膜系结构与折射率（ n_H 、 n_L 、 n_s ）；(b) 三条代表性反射光谱，虚线为 $\lambda_{\text{target}} = 480 \text{ nm}$ ；(c) 5000 组样本在目标波长处的反射率分布，橙色虚线为物理上限。

2.2 个人目标波长与随机种子

学号后两位为 N 时 $\lambda_{\text{target}} = 450 + 10 \times (N \bmod 31) \text{ nm}$ ；seed 取学号后 6 位，控制数据生成、划分与模型初始化；设计阶段取 $\text{design_seed} = \text{seed} + 1$ 以避免候选与训练数据重复。本人学号后两位为 03，故 $\lambda_{\text{target}} = 480 \text{ nm}$ ， $\text{seed} = 303003$ ， $\text{design_seed} = 303004$ 。

2.3 数据集生成

用 numpy 传统随机数接口（`np.random.seed` 与 `np.random.rand`，该接口有跨版本流一致性保证）在 40–180 nm 内均匀采样 5000 组四层膜厚，并用 TMM 计算 41 个波长处的反射率。随后固定划分：随机排列后的前 4000 组为训练池、其后 500 组为验证集、末 500 组为测试集，该划分全程不变；数据量实验中的“ N 组”即训练池中的前 N 组。

2.4 MLP 代理模型

MLP 输入为归一化到 $[0, 1]$ 的四层膜厚 $(d - 40)/140$ ，输出为 41 点反射率。结构为 4–128–128–64–41，隐藏层用 ReLU，输出层线性，参数量约 2.8×10^4 。损失为均方误差（MSE），优化器 Adam（学习率 3×10^{-3} ，批大小 256），最多训练 4000 轮，以验证集损失早停（耐心 400 轮）并取验证集最优权重。数组运算与自动微分分别由 NumPy^[10] 与 PyTorch^[11] 提供，训练在 CPU 上完成，单次约 211.7 s；数据量实验中各模型除样本数与初始化种子外超参数完全一致。




图 3 MLP 代理模型结构: 输入 4 层膜厚, 经 128–128–64 三个隐藏层, 输出 41 点反射率。

2.5 训练数据量实验

从固定训练池中依次取前 500、1000、2000、4000 组训练, 验证集与测试集固定不变; 每水平用 3 个种子重复以抑制初始化波动, 并对 MSE-样本数做双对数拟合得到幂律指数 α 。

2.6 MLP 辅助薄膜筛选

用 `design_seed` 在 40–180 nm 内均匀生成 10000 组候选, MLP 预测其 41 点光谱后按 λ_{target} 处反射率降序取前 10 名。为检验排名可信度, 对全部候选重算 TMM 真值, 计算预测与真值排序的 Spearman 系数、Top10 召回率, 并按真值重排得到最终 Top5。性能参照为 λ_{target} 处的物理上限, 由解析四分之一波长条件与全局优化分别给出。

3. 结果

3.1 训练与光谱预测

基础模型 (4000 组训练) 在 4000 轮内收敛, 验证集最优出现在第 3986 轮, 验证集 MSE 为 8×10^{-5} ; 训练集与验证集损失曲线几乎重合 (图 4), 说明该规模下未出现明显过拟合。




图 4 训练集与验证集的损失曲线: (a) 全部 4000 轮; (b) 收敛段放大, 虚线标注验证集最优轮次。

固定测试集 (500 组) 上 MAE 为 0.00638, RMSE 为 0.0086, $R^2 = 0.9977$, 单点最大绝对偏差 0.054; 短波端误差略大 (400 nm 处 0.0135), 长波端最小 (780 nm 处 0.0038)。图 5 给出三个代表性样本, 误差较大者在 400–550 nm 明显振荡。目标波长处预测与真值的 Pearson 相关系数为 0.9984, MAE = 0.00786, 偏差 +0.00093。




图5 测试集上 TMM 真值与 MLP 预测的光谱对比：(a)(b)(c) 误差由小到大的三个代表性样本；(d) 目标波长处的预测—真值散点。

3.2 训练数据量的影响

训练样本数从 500 增至 4000（每水平 3 个种子），测试集 MSE 由 6×10^{-4} 降至 7×10^{-5} ，MAE 由 0.0171 降至 0.0063。双对数拟合给出 $\text{MSE} \propto N^{(-1.031)}$ ， $R^2 = 0.9910$ （图 6a）。从 500 增至 1000 组误差下降约 56.7%，而从 2000 增至 4000 组仅再降 41.7%，边际收益递减明显（图 6b）。种子间标准差（约 3×10^{-5} ）远小于不同数据量之间的差异，说明该趋势来自数据量而非初始化。




图6 训练样本数对测试误差的影响：(a) 双对数坐标下的幂律关系；(b) 平均绝对误差与边际收益递减。

3.3 MLP 辅助薄膜设计

用 `design_seed` 生成 10000 组候选膜厚，MLP 预测并按 λ_{target} 处的反射率排序，再对全部候选做 TMM 复核（图 7b）：MLP 预测值与真值在目标波长处的 Spearman 相关系数为 0.9983，Pearson 相关系数 0.9984；MLP 排序的 Top10 中有 60% 落在 TMM 排序的 Top10 内，Top5 召回率 80%；MLP 排名第 1 的候选恰好也是全批 10000 组中 TMM 真值最高的结构，真值 $R(480 \text{ nm}) = 0.6579$ ，处于候选池的 99.99 分位。作为对照，若完全不用代理模型、从同一候选池随机抽取同样 10 组（独立重复 10^5 次），其最优者 R 的均值为 0.5702、99 分位为 0.6519；MLP 所选出随机均值 0.0876，随机取片超过它的概率仅 0.12%，说明增益来自代理模型本身而非候选池的先天质量。

按 TMM 真值重排后得到的最终 Top5 见表 1，五组设计的真值反射率落在 0.6521–0.6579 之间，均处于候选池前 0.1%。图 7a 给出最终设计的光谱：MLP 预测与 TMM 真值高度重合，但在目标波长处给出 0.6657 的预测值，高于物理上限 0.6589，说明代理模型在极值附近倾向于外推。

为确认这一性能参照的可靠性，本文用两条独立路径求 λ_{target} 处的反射率上限。解析路径由四分之一波长条件给出，对应膜厚 52.17/82.76/52.17/82.76 nm， $R = 0.6589$ ；数值路径先用差分进化与 41 个起点的 L-BFGS-B 局部优化，再对四维膜厚空间做每层 41 点的密集网格穷举（共 2.83×10^6 个评价点）并逐级细化，两条路径的最优值相差仅 8×10^{-6} 。网格搜索还揭示了一个精确对称性：单层特征矩阵满足 $M(\delta + \pi) = -M(\delta)$ ，而反射率只依赖 C/B ，符号自动抵消，因此任意层增加半个波长的光学厚度不改变光谱。在 40–180 nm 的盒约束内，两片高折射率层可分别取 52.17 nm 或 156.52 nm，构成 4 个在 λ_{target} 处完全等价的解（反射率差异为 0.0000）。这解释了候选池中高分结构的形貌：全批 TMM 最优解的 d_1 为 158.56 nm 而非 52.17 nm，两者正是这一家族中的两个成员。

代理模型的分辨率存在上限。候选池顶部 1%（100 组）的真值跨度为 0.0252，约为 MLP 在目标波长处预测误差（0.00786）的 3 倍，该量级上的排序可信；但顶部 0.1%（10 组）的跨度仅 0.0069，小于模型误差，最优集合内部的精确名次不可分辨。因此代理模型的价值在于把候选规模从 10^4 压缩到 10，而非给出唯一的第 1 名。

一个自然的改进方向是让损失函数偏向设计关心的波长。把 λ_{target} 处的权重提高到 10 倍重新训练后，目标波长处的测试 MAE 由 0.00786 降至 0.00597（改善 24.0%），候选池的 Spearman 相关系数升至 0.9989；但 MLP 的 Top1 不再等同于 TMM 真值最优（该最优仍落在其 Top10 之内）。这与上述分辨率极限一致：提高单点精度能改善整体排序，却无法消除最优尾部名次抖动。




图 7 (a) 最终设计的 MLP 预测光谱与 TMM 复核光谱（标注目标波长与物理上限）；

(b) 10000 组候选的预测—真值排名一致性。

3.4 代表性失败案例与误差来源

图 8a 给出误差最大的测试样本：四层膜厚为 179.9, 158.6, 147.6, 73.5 nm，MLP 在 400–500 nm 区间系统性高估，单样本 MAE 达 0.0149，约为整体平均值的 2.3 倍。为定位失败机理，本文考察了四类候选解释，只有一类成立。

第一，波长采样不足可以直接排除：干涉条纹间距的中位数为 180 nm、最小 120 nm，按 Nyquist 判据只需 ≤ 60 nm，而本文用 10 nm，冗余 6 倍。第二，光谱陡峭度与膜厚灵敏度均只有弱相关或不显著：逐样本 MSE 与相邻波长平均变化幅度的相关系数为 0.207 ($r^2 = 0.043$)，与总光学厚度为 0.148，与差分法估计的 $|\partial R / \partial d|$ 为 -0.078（不显著）。第三，局部采样密度相关性最强：测试样本到训练集的第 10 近邻距离与逐样本 MSE 的相关系数为 0.370 ($r^2 = 0.137$)，最稀疏组的平均 MSE 比最密集组高 48%（图 8b）。四类解释中只有局部采样密度成立，故它是数据侧的主导因素；但它只解释了 0.137 的方差，模型侧的因素尚未排除，下一节继续检验。




图 8 代表性失败案例：(a) 最大误差样本（膜厚 179.9, 158.6, 147.6, 73.5 nm）的 TMM 与 MLP 光谱，插图预测残差 ΔR ；(b) 逐样本误差与局部采样密度的关系。

表 1 MLP 筛选并以 TMM 复核后的最终 Top5 膜系设计。

排名	d_1 / nm	d_2 / nm	d_3 / nm	d_4 / nm	MLP 预测 R(480 nm)	TMM 复核 R(480 nm)
1	158.56	78.79	52.45	79.09	0.6657	0.6579
2	159.74	81.98	53.39	69.31	0.6605	0.6555
3	154.00	83.05	162.28	82.86	0.6581	0.6538
4	156.62	75.24	158.15	98.71	0.6557	0.6536
5	151.09	94.14	48.35	81.04	0.6558	0.6521

3.5 误差瓶颈：容量与数据量的耦合

3.4 节的四类解释都在数据与光学一侧，采样密度也只解释了 0.137 的方差，因此还需考察模型侧的因素。先做容量对照：在与基准完全相同的训练数据、划分、种子与超参数下只改变隐藏层结构，把参数量从 2.8×10^4 降到 2.4×10^3 ，测试 MSE 升至基准的 9.1 倍；增至 1.1×10^5 ，则再降 58% ($R^2 = 0.9991$)。可见容量不足会系统性抬高误差，容量充足时局部采样稀疏才成为主导因素。

容量与数据量并不独立。把 3 种容量与 4 种样本数放在同一网格上（共 12 个配置，除结构与样本数外设置完全一致；为与容量对照同口径，每个配置均用同一初始化种子单次训练），可以看到幂律指数 α 本身就依赖容量：小容量下 $\alpha = 0.43$ ，基准 0.98，大容量 1.38（图 9）。基准容量下的 α 与 3.2 节基于 3 个种子平均得到的 1.031 略有差异，属种子波动范围。因此“误差按 $N^{-(1.031)}$ 下降”只是中等容量下的结论，并非普适规律。

容量与数据的互补性在两个端点上最清楚。样本只有 500 组时，大容量的测试 MSE (5.7×10^{-4}) 与基准 (5.4×10^{-4}) 基本相同，容量优势无从体现；样本增至 4000 组后，大容量比基准低 58%。反过来，小容量模型的 α 明显偏低，说明它无法充分利用更多样本——此时继续增加数据，收益会被容量瓶颈吞掉。

由此得到明确的取舍依据：数据与容量必须匹配。在本体系下，若样本量在 4000 组量级，把容量提高到 10^5 是划算的；而若样本只有 500 组，加大容量几乎无效，应优先扩充样本。

容量带来的精度提升也会直接转化为筛选能力。用同一批 10000 组候选、同一套 TMM 真值，只把代理模型换成大容量版本，目标波长处的预测 MAE 由 0.00786 降到 0.00517，与真值的排序一致性由 0.9983 升到 0.9992，Top10 召回率从 60% 提高到 80%。对照 3.3 节的分辨率分析可以理解这一改善：基准模型的预测误差（0.00786）大于候选池顶部 0.1% 的真值跨度（0.0069），故尾部名次不可分辨；大容量模型把误差压到 0.00517 后已接近该跨度，筛选质量随之提升。分辨率极限并非固定常数，但突破它需要付出容量成本。




图 9 网络容量与训练样本量的耦合：三种容量下测试 MSE 随样本量的变化（双对数坐标），括号内为各自的幂律指数 α ，点线为 $\alpha = 1$ 的参考斜率。

4. 讨论

MLP 对“膜厚—光谱”映射的学习效果总体良好：测试集 $R^2 = 0.9977$ ，目标波长处相关系数达 0.9984。失败样本的归因（3.4、3.5 节）表明，限制精度的不是光谱的高频成分（10 nm 采样对最小条纹间距仍有约 6 倍冗余），而是训练样本在四维膜厚空间中的局部稀疏与网络容量这两类因素，且两者互为条件——容量不足时数据的收益被吞掉，容量充足时局部稀疏才成为主导。其可操作性在于：既可在误差较大的区域补充样本，适度增大网络容量也仍有收益，但需注意二者必须匹配。

数据量效应显示误差按 $N^{-(1.031)}$ 下降且边际收益递减：从 500 组增至 1000 组的收益远大于从 2000 组增至 4000 组。这与泛化误差随训练集规模幂律下降的经验规律一致^[12]，说明在固定网络容量下继续增加均匀随机样本的收益有限；而容量本身是可调自由度，前节的容量对照表明它在当前规模下仍有可观收益。需说明的是，该拟合仅基于 4 个数据量水平、每个水平 3 个种子，全部在固定容量下完成， α 应视为固定容量下的趋势性估计。3.5 节进一步表明，把容量提高一个量级可将该指数抬到 1.38，即容量与数据互为条件，单独讨论任一方都会失真。

代理模型的价值需要谨慎界定。在 10000 组候选、四层膜这一简单体系下，TMM 穷举仅需 0.27 s，而“MLP 预测全部候选 + TMM 复核 Top10”需 0.004 s，绝对耗时都很小；批量推理时 MLP 的单候选耗时约为 TMM 的 1/119，但单点调用因框架固定开销反而不占优势。按实测，要把训练开销赚回来需筛选约 9.6×10^6 个候选——在四层膜这一简单体系下，代理模型在经济上并不划算。其真正价值在于前向计算昂贵（层数多、含色散与吸收、斜入射）或候选空间极大的场景。即便排名一致性很高，基准精度下的代理模型也难以分辨最优尾部：顶部 0.1% 候选的真值跨度（0.0069）小于其预测误差（0.00786）；把 λ_{target} 处权重提高 10 倍可将该处误差降至 0.00597，Top1 的身份仍不稳定。3.5 节则显示，把容量提高一个量级可把误差压到 0.00517、Top10 召回率升至 80%——分辨率极限可以被逼近，但要付出容量成本。稳妥的分工仍是“代理模型压缩候选规模、TMM 最终裁决”。

本研究有四点局限。第一，采样密度只解释了误差方差的 0.137；容量对照已确认容量是其中一项重要因素，其余来源（如优化随机性、谱形复杂度）尚未定位。第二，局部加密实验中的加密样本与高反射测试集取自同一分布（ σ 相同、种子不同、无重叠），故它证明的是“数据分布与目标区域匹配”的收益，而非跨分布泛化能力。第三，本文采用固定折射率、无吸收、正入射的简化模型，实际膜系还需考虑色散、吸收与角度依赖。第四，公差分析显示整体厚度偏差 $\pm 1\%$ 时目标波长反射率仅降 0.0010，逐层 $\sigma = 2 \text{ nm}$ 时平均降 0.0018、最差降 0.0158，说明设计对制造误差总体不敏感，但极端误差仍会削弱性能。

5. 结论

本文用 TMM 数据训练 MLP 代理模型并用于目标波长设计。结果表明：MLP 能准确预测反射光谱（测试集 $R^2 = 0.9977$ ）；误差随训练样本数按 $N^{-1.031}$ 幂律下降并呈边际收益递减，且该指数随容量在 0.43–1.38 间变化；在 10000 组候选中其排序与 TMM 真值的相关系数达 0.9983，所选设计经 TMM 复核达理论上限的 99.8%。代理模型适合压缩候选规模，尾部名次仍需 TMM 裁决。

数据与代码可用性

本研究所用数据由本文 TMM 代码生成。全部源代码、训练与筛选脚本、环境依赖及复现说明见仓库：

<https://github.com/Amao0333/ai4s-mlp-thinfilm>

README 记录了个人参数 $\lambda_{\text{target}} = 480 \text{ nm}$ 、 $\text{seed} = 303003$ 、 $\text{design_seed} = 303004$ ，以及环境配置、数据生成、模型训练、结果复现与筛选步骤；论文全部数值与图件均由该仓库脚本生成。

参考文献

- [1] MACLEOD H A. Thin-Film Optical Filters[M/OL]. 5th ed. Boca Raton: CRC Press, 2017. DOI:10.1201/b21960.
- [2] 唐晋发, 顾培夫, 刘旭, 等. 现代光学薄膜技术[M]. 杭州: 浙江大学出版社, 2006.
- [3] SULLIVAN B T, DOBROWOLSKI J A. Implementation of a numerical needle method for thin-film design[J/OL]. Applied Optics, 1996, 35(28): 5484-5492. DOI:10.1364/ao.35.005484.
- [4] MA T, MA M, GUO L J. Optical multilayer thin film structure inverse design: From optimization to deep learning[J/OL]. iScience, 2025, 28(4): 112222. DOI:10.1016/j.isci.2025.112222.
- [5] PEURIFOY J, SHEN Y, JING L, et al. Nanophotonic particle simulation and inverse design using artificial neural networks[J/OL]. Science Advances, 2018, 4(6): eaar4206. DOI:10.1126/sciadv.aar4206.
- [6] LIU D, TAN Y, KHORAM E, et al. Training Deep Neural Networks for the Inverse Design of Nanophotonic Structures[J/OL]. ACS Photonics, 2018, 5(4): 1365-1369. DOI:10.1021/acsp Photonics.7b01377.
- [7] MA T, WANG H, GUO L J. OptoGPT: A foundation model for inverse design in optical multilayer thin film structures[J/OL]. Opto-Electronic Advances, 2024, 7(7): 240062. DOI:10.29026/oea.2024.240062.
- [8] SWE S K, NOH H. Inverse Design of Reflectionless Thin-Film Multilayers with Optical Absorption Utilizing Tandem Neural Network[J/OL]. Photonics, 2024, 11(10): 964. DOI:10.3390/photonics11100964.
- [9] MALKIEL I, MREJEN M, NAGLER A, et al. Plasmonic nanostructure design and characterization via Deep Learning[J/OL]. Light: Science & Applications, 2018, 7(1): 60. DOI:10.1038/s41377-018-0060-7.
- [10] HARRIS C R, MILLMAN K J, VAN DER WALT S J, et al. Array programming with NumPy[J/OL]. Nature, 2020, 585(7825): 357-362. DOI:10.1038/s41586-020-2649-2.
- [11] PASZKE A, GROSS S, MASSA F, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[C/OL]//Advances in Neural Information Processing Systems: Vol. 32. Curran Associates, Inc., 2019. <https://arxiv.org/abs/1912.01703>.
- [12] HESTNESS J, NARANG S, ARDALANI N, et al. Deep Learning Scaling is Predictable, Empirically[EB/OL]. arXiv, 2017: arXiv:1712.00409. <https://arxiv.org/abs/1712.00409>.