

RESEARCH ARTICLE

基于多层感知机的多层介质薄膜光谱预测与辅助设计

MLP-Based Spectral Prediction and Data-Driven Design of Multilayer Dielectric Thin Films

姓名：_____ 学号：2023303003

 λ_{target} : 480 nm seed: 303003 design_seed: 303004

摘要

多层介质薄膜的反射光谱由各层厚度通过干涉效应决定，而“厚度到光谱”的正向计算需要传输矩阵法（TMM）逐点求解，在需要评估大量候选结构时计算代价不可忽略。本文以统一模型 Air/H/L/H/L/Glass（ $n_H = 2.30$ ， $n_L = 1.45$ ， $n_s = 1.52$ ，膜厚 40–180 nm）为研究对象，用 TMM 生成 5000 组“膜厚—反射光谱”数据（400–800 nm，步长 10 nm，共 41 点），按 4000/500/500 固定划分，训练 4–128–128–64–41 的多层感知机（MLP）代理模型，围绕预测精度、训练数据量效应与辅助设计能力三个问题展开。测试集上 MLP 的平均绝对误差为 0.00638，决定系数 R^2 为 0.9977；在目标波长 480 nm 处预测与真值的 Pearson 相关系数为 0.9984。误差随训练样本数按 $N^{-(1.031)}$ 的幂律下降，边际收益递减。用 design_seed 生成 10000 组候选结构，MLP 预测值与 TMM 真值在目标波长处的 Spearman 排序相关系数为 0.9983，Top10 召回率为 60%；最终设计经 TMM 复核得到 $R(480 \text{ nm}) = 0.6579$ ，达到四分之一波长解析上限 0.6589 的 99.8%。结果表明 MLP 可作为低成本的代理模型用于候选结构快速筛选，但最终设计必须由 TMM 复核。

关键词：光学薄膜；传输矩阵法；多层感知机；代理模型；AI for Science

1. 引言

多层介质薄膜由高、低折射率材料交替堆叠而成，其反射特性来自各界面反射光之间的干涉。在正入射、无吸收、忽略色散的条件下，给定各层折射率与厚度，光谱响应完全确定；反之，要在某波长获得特定反射率则需确定各层厚度，这是多变量、非线性的设计问题。四分之一波长条件给出了经典解，但膜厚的周期性与光谱的多峰特性使“厚度—光谱”映射呈现强非线性。

传输矩阵法（TMM）是计算多层膜光谱的经典方法：把每层写成一个 2×2 特征矩阵，沿膜系连乘后由等效导纳得到反射率。单条光谱的计算开销很小，但当设计流程需要评估上万组候选结构时，累积代价迅速上升；若再考虑色散、斜入射与吸收，单次前向计算的成本还会显著增加。

机器学习代理模型提供了另一条路径：用数据学习“膜厚到光谱”的映射，以极低的推理成本替代物理计算，用于大规模候选的初筛，最终结果再由物理模型复核——这正是 AI for Science 的典型范式。本文围绕三个问题展开：（1）MLP 能否准确预测反射光谱；（2）训练数据量增加后预测误差如何变化；（3）MLP 能否作为辅助手段完成目标波长下的薄膜设计。研究对象、目标波长与随机种子均按课程要求由学号统一确定，全部结果可由公开代码复现。

****图 1**** 本研究的总体流程：TMM 生成数据、MLP 训练与预测、数据量实验、辅助设计与 TMM 复核。

2. 材料与方法

2.1 光学模型与传输矩阵法

研究对象统一为 Air/H/L/H/L/Glass 四层介质膜，正入射、无吸收并忽略色散。高、低折射率材料分别取 $n_H = 2.30$ 与 $n_L = 1.45$ ，玻璃基底 $n_s = 1.52$ ，入射介质为空气 $n_0 = 1.00$ ，每层膜厚在 40–180 nm 内变化，波长范围为 400–800 nm、步长 10 nm，共 41 个采样点。

第 i 层的位相厚度为

$$\delta_i = 2\pi n_i d_i / \lambda$$

其特征矩阵为

$$M_i = \begin{bmatrix} \cos \delta_i & i \sin \delta_i / \eta_i \\ i \eta_i \sin \delta_i & \cos \delta_i \end{bmatrix}$$

其中正入射下光学导纳 $\eta_i = n_i$ （自由空间单位）。整个膜系的特征矩阵为各层矩阵按入射到出射顺序的连乘 $M = M_1 M_2 M_3 M_4$ ，由

$$[B; C] = M [1; \eta_s]$$

得到等效导纳 $Y = C/B$ ，反射系数与反射率分别为

$$r = (\eta_0 - Y) / (\eta_0 + Y), R = |r|^2$$

本文用两套独立实现计算 R ：一是上述特征矩阵连乘；二是从基底出发的等效导纳递推 $Y \leftarrow (Y \cos \delta + i \eta \sin \delta) / (\cos \delta + i (Y/\eta) \sin \delta)$ 。二者数学等价但代码路径不同，用于互相验错。校核结果：裸基底反射率与解析值 4.258% 相差 7×10^{-18} ；四分之一波长膜系在 480 nm 处与导纳链解析值 0.6589 相差 1×10^{-16} ；200 组随机单层膜与单层膜解析式的最大偏差 6×10^{-16} ；两套实现作用于 2000 组随机膜厚（41 个波长）的最大差异 9×10^{-16} ； $R + T = 1$ 的最大偏差 1×10^{-15} 。另用在线 TMM 工具对 5 个代表性膜系独立核对，最大偏差 6×10^{-16} 。




图 2 物理模型与 TMM 数据生成，包括膜系结构、三条代表性反射光谱与 5000 组样本在目标波长处的反射率分布。

2.2 个人目标波长与随机种子

设学号后两位为 N ，目标波长 $\lambda_{\text{target}} = 450 + 10 \times (N \bmod 31) \text{ nm}$ ；随机种子取学号后 6 位整数，设计阶段的种子取 $\text{design_seed} = \text{seed} + 1$ ，以避免候选膜厚与训练数据重复。本人学号后两位为 03，因此 $\lambda_{\text{target}} = 480 \text{ nm}$ ； $\text{seed} = 303003$ ； $\text{design_seed} = 303004$ 。数据生成、数据划分与模型初始化均由 seed 控制。

2.3 数据集生成

按 `numpy` 传统随机数接口（`np.random.seed` 与 `np.random.rand`，该接口具有跨版本流一致性保证），在 40–180 nm 内均匀采样生成 5000 组四层膜厚，并用 TMM 计算每组在 41 个波长处的反射率。随后用一次性随机排列固定划分：排列后的前 4000 组为训练池、其后 500 组为验证集、最后 500 组为测试集。该划分在本文所有实验中保持不变；数据量实验中的“ N 组训练样本”即训练池中的前 N 组。




图 3 MLP 代理模型结构：输入 4 层膜厚，经 128–128–64 三个隐藏层，输出 41 点反射率。

2.4 MLP 代理模型

MLP 输入为归一化到 $[0, 1]$ 的四层膜厚 $(d - 40)/140$ ，输出为 41 个波长采样点的反射率。网络结构为 4-128-128-64-41，隐藏层激活函数为 ReLU，输出层为线性层，参数量约 2.7×10^4 。损失函数为均方误差（MSE），优化器为 Adam，学习率 3×10^{-3} ，批大小 256，最多训练 4000 轮，以验证集损失为早停判据（耐心 400 轮），并保存验证集最优的权重用于测试与筛选。所有训练均在 CPU 上完成，单次训练耗时约 211.7 s。为公平比较，数据量实验中各模型除训练样本数与初始化种子外，全部超参数完全一致。

2.5 训练数据量实验

从固定训练池中依次取前 500、1000、2000、4000 组训练模型，验证集与测试集始终为固定的 500 组。考虑到不同初始化会带来随机波动，每个数据量水平用 3 个初始化种子重复训练，报告平均值与标准差。同时对“测试集 MSE 随训练样本数”做双对数线性拟合，得到幂律指数 α 作为数据量效应的定量描述。

2.6 MLP 辅助薄膜筛选

用 `design_seed` 在 40–180 nm 内均匀生成 10000 组新候选膜厚，用训练好的 MLP 预测其 41 点反射光谱，按 λ_{target} 处的预测反射率降序排序，取前 10 名。为检验排名的可信度，本文对全部 10000 组候选都用 TMM 重新计算真值，进而计算 MLP 预测与真值排序的 Spearman 相关系数、MLP Top10 与 TMM Top10 的重合比例（召回率），并把 MLP 的 Top10 按 TMM 真值重排，得到最终 Top5 设计。作为性能参照，本文还用解析四分之一波长条件与全局优化（差分进化 + 多起点 L-BFGS-B）求出了 λ_{target} 处反射率的物理上限。

3. 结果

3.1 训练与光谱预测

基础模型（4000 组训练）在 4000 轮内收敛，验证集最优出现在第 3986 轮，验证集 MSE 为 8×10^{-5} ；训练集与验证集损失曲线几乎重合（图 4），说明该规模下未出现明显过拟合。




图 4 训练集与验证集的损失曲线。

在固定测试集（500 组）上，MLP 预测的平均绝对误差 MAE 为 0.00638，均方根误差 RMSE 为 0.0086，决定系数 $R^2 = 0.9977$ ，单点最大绝对偏差 0.054。逐波长看，短波端误差略大（400 nm 处 MAE = 0.0135），长波端最小（780 nm 处 MAE = 0.0038），与短波端光谱变化更剧烈一致。图 5 给出三个代表性测试样本的光谱对比：误差较小的样本其光谱较为平缓，误差较大的样本在 400–550 nm 区间存在明显振荡。在目标波长 480 nm 处，预测与真值的 Pearson 相关系数为 0.9984，MAE = 0.00786，偏差 +0.00093。




图5 测试集上 TMM 真值与 MLP 预测的光谱对比，以及目标波长处的预测—真值散点。

3.2 训练数据量的影响

固定验证集与测试集，训练样本数从 500 增加到 4000（每个水平 3 个初始化种子），测试集 MSE 从 6×10^{-4} 降至 7×10^{-5} ，平均绝对误差从 0.0171 降至 0.0063。双对数拟合给出幂律关系 $\text{MSE} \propto N^{(-1.031)}$ ，拟合优度 $R^2 = 0.9910$ （图 6a）。从 500 增至 1000 组时误差下降约 56.7%，而从 2000 增至 4000 组时仅再下降 41.7%，呈明显的边际收益递减（图 6b）。三个种子之间的标准差（约 3×10^{-5} ）明显小于不同数据量之间的差异，说明该趋势来自数据量而非随机初始化。




图6 训练样本数对测试误差的影响：(a) 双对数坐标下的幂律关系；(b) 平均绝对误差与边际收益递减。

3.3 MLP 辅助薄膜设计

用 `design_seed` 生成 10000 组候选膜厚，MLP 预测并按 λ_{target} 处的反射率排序。对全部候选做 TMM 复核后可以看到（图 7b）：MLP 预测值与真值在目标波长处的 Spearman 相关系数为 0.9983，Pearson 相关系数 0.9984；MLP 排序的 Top10 中有 60% 落在 TMM 排序的 Top10 内，Top5 召回率 80%。MLP 排名第 1 的候选恰好也是全批 10000 组中 TMM 真值最高的结构，其真值 $R(480 \text{ nm}) = 0.6579$ ，处于候选池的 99.99 分位。

按 TMM 真值重排后得到的最终 Top5 见表 1。五个设计的真值反射率落在 0.6521–0.6579 之间，均处于候选池的前 0.1%。图 7a 给出最终设计的光谱：MLP 预测与 TMM 真值高度重合，但 MLP 在目标波长处给出了 0.6657 的预测值，略高于物理上限 0.6589，这一过高估计（约 0.0068）说明代理模型在极值附近倾向于外推。

作为参照， λ_{target} 处的物理上限为四分之一波长条件的解析值 0.6589，对应膜厚 52.17/82.76/52.17/82.76 nm；全局优化（差分进化与多起点局域优化）独立收敛到同一数值，说明该波长下的可达反射率上限即由四分之一波长解给出。因此候选池中的最优结构（0.6579）已达到理论上限的 99.8%。




图 7 (a) 最终设计的 MLP 预测光谱与 TMM 复核光谱（标注目标波长与物理上限）；
(b) 10000 组候选的预测—真值排名一致性。

表 1

排名	d_1 / nm	d_2 / nm	d_3 / nm	d_4 / nm	MLP 预测 R(480 nm)	TMM 复核 R(480 nm)
1	158.56	78.79	52.45	79.09	0.6657	0.6579
2	159.74	81.98	53.39	69.31	0.6605	0.6555
3	154.00	83.05	162.28	82.86	0.6581	0.6538
4	156.62	75.24	158.15	98.71	0.6557	0.6536
5	151.09	94.14	48.35	81.04	0.6558	0.6521

3.4 代表性失败案例

逐样本误差与光谱陡峭度显著相关：逐样本 MSE 与“光谱相邻点平均变化幅度”的 Pearson 相关系数为 0.207 ($p = 3 \times 10^{-6}$)，与总光学厚度的相关系数为 0.148；而与目标波长处的反射率水平几乎不相关 (-0.035)。图 8a 给出误差最大的测试样本：其四层膜厚为 179.9, 158.6, 147.6, 73.5 nm，光谱在 400–500 nm 内快速起伏，MLP 在该区间系统性高估或低估，单样本 MAE 达 0.0149，约为整体平均值的 2.3 倍。图 8b 显示误差随光谱陡峭度上升的整体趋势，说明失败主要发生在光谱高频成分强的样本上。




图 8 代表性失败案例：(a) 最大误差样本的 TMM 与 MLP 光谱；(b) 逐样本误差与光谱陡峭度的关系。

4. 讨论

MLP 对“膜厚—光谱”映射的学习效果总体良好：测试集 $R^2 = 0.9977$ ，目标波长处的相关系数达 0.9984。主要误差来源不是模型容量，而是光谱自身的高频成分：膜厚越大，相邻采样点的干涉条纹越密集，在 10 nm 采样间隔下逼近采样极限，网络难以同时拟合不同样本的快速振荡。这解释了为何逐样本误差与光谱陡峭度正相关 ($r = 0.207$)，而与目标波长处的反射率水平几乎无关。

数据量效应显示误差按 $N^{-1.031}$ 下降且边际收益递减：从 500 组增至 1000 组的收益远大于从 2000 组增至 4000 组。这与深度学习中泛化误差随训练集规模幂律下降的经验规律一致，说明在给定采样间隔与网络容量下，继续增加均匀随机样本的收益有限；若要进一步降低误差，提高波长采样密度或在误差较大的区域加密采样比单纯扩大样本量更有效。

代理模型在设计环节的价值需要谨慎界定。在 10000 组候选、四层膜这一简单体系下，TMM 穷举仅需 0.42 s，而“MLP 预测全部候选 + TMM 复核 Top10”需 0.005 s，绝对耗时都很小；批量推理时 MLP 的单候选耗时约为

TMM 的 1/138，但单点调用时由于深度学习框架的固定开销反而不占优势。按实测，候选规模需超过约 501 组，代理模型节省的时间才能收回训练成本。因此它的真正价值在于前向计算昂贵（层数多、含色散与吸收、斜入射、大批量参数扫描）或候选空间极大的场景。另一方面，MLP 的排名与实际最优高度一致（Spearman 0.9983），说明它确实能完成初筛：把需要精确计算的结构从 10000 组压缩到 10 组，且没有错过全批最优解。

本研究存在四点局限。第一，10 nm 采样间隔对厚膜样本的快速干涉条纹存在欠采样，既限制了可学习的信息量，也限制了精度上限。第二，训练数据在目标波长的高反射尾部相对稀疏（真值超过 0.6 的样本仅占 4.8%），模型在极值附近乐观（对最优候选高估约 0.0068）；补充实验表明，在四分之一波长解附近以 $\sigma = 15$ nm 加密采样并替换 500 组训练样本后，高反射测试集 MSE 由 1×10^{-4} 降至 4×10^{-5} （-61.1%），代价是标准测试集上升 +16.9%，说明数据分布与目标区域的匹配比样本总量更关键。第三，本文采用固定折射率、无吸收、正入射的简化模型，实际膜系还需考虑色散、吸收与角度依赖。第四，公差分析显示整体厚度偏差 $\pm 1\%$ 时目标波长反射率仅下降 0.0008，逐层随机误差 $\sigma = 2$ nm 时平均下降 0.0018、最差情形下降 0.0158，说明该设计对制造误差总体不敏感，但极端误差仍会明显削弱性能。

5. 结论

本文以 Air/H/L/H/L/Glass 四层介质膜为对象，用 TMM 生成 5000 组“膜厚—光谱”数据并训练 4-128-128-64-41 的 MLP 代理模型，得到三点结论。第一，MLP 能够准确预测反射光谱：测试集 $R^2 = 0.9977$ 、MAE = 0.00638，目标波长处相关系数 0.9984。第二，误差随训练样本数按幂律下降（ $MSE \propto N^{(-1.031)}$ ）并呈边际收益递减，从 2000 组增至 4000 组仅带来 41.7% 的额外改善。第三，MLP 可以作为代理模型辅助设计：在 10000 组候选中其排序与 TMM 真值的 Spearman 系数为 0.9983，选出的最优结构与全批 TMM 最优一致，TMM 复核反射率 0.6579，达四分之一波长理论上限 0.6589 的 99.8%，但最终结果必须由 TMM 复核，且代理模型在极值附近存在约 0.0068 的乐观偏差。

数据与代码可用性

本研究所用数据全部由本文 TMM 代码生成。全部源代码、模型训练脚本、薄膜筛选脚本、环境依赖与复现说明可在以下仓库获取：

<https://github.com/USERNAME/REPOSITORY>

仓库中 README 记录了个人参数 $\lambda_{\text{target}} = 480$ nm、seed = 303003、design_seed = 303004，以及环境配置、数据生成、模型训练、结果复现与薄膜筛选的完整步骤。论文中全部数值与图件均可由该仓库脚本复现。

参考文献

- [1] Ma T, Ma M, Guo L J. Optical multilayer thin film structure inverse design: from optimization to deep learning. *iScience*, 2025, 28: 112222.
- [2] Macleod H A. *Thin-Film Optical Filters*. 5th ed. Boca Raton: CRC Press, 2018.
- [3] 唐晋发, 顾培夫, 刘旭, 等. 现代光学薄膜技术. 杭州: 浙江大学出版社, 2006.
- [4] Peurifoy J, Shen Y, Jing L, et al. Nanophotonic particle simulation and inverse design using artificial neural networks. *Science Advances*, 2018, 4(6): eaar4206.
- [5] Liu D, Tan Y, Khoram E, et al. Training deep neural networks for the inverse design of nanophotonic structures. *ACS Photonics*, 2018, 5(4): 1365-1369.
- [6] Malkiel I, Mrejen M, Nagler A, et al. Plasmonic nanostructure design and characterization via deep learning. *Light: Science & Applications*, 2018, 7: 60.
- [7] Ma T, Wang H, Guo L J. OptoGPT: a foundation model for inverse design in optical multilayer thin film structures. *Opto-Electronic Advances*, 2024, 7(7): 240062.
- [8] Meng F, Ding J, Zhao Y, et al. Inverse design of reflectionless thin-film multilayers with optical absorption utilizing tandem neural network. *Photonics*, 2024, 11(10): 964.
- [9] Sullivan B T, Dobrowolski J A. Implementation of a numerical needle method for thin-film design. *Applied Optics*, 1996, 35(28): 5484-5492.
- [10] Hestness J, Narang S, Ardalani N, et al. Deep learning scaling is predictable, empirically. *arXiv:1712.00409*, 2017.
- [11] Harris C R, Millman K J, van der Walt S J, et al. Array programming with NumPy. *Nature*, 2020, 585: 357-362.
- [12] Paszke A, Gross S, Massa F, et al. PyTorch: an imperative style, high-performance deep learning library. In: *Advances in Neural Information Processing Systems*, 2019, 32: 8024-8035.